UNIVERSITAT POLITÈCNICA DE VALÈNCIA

Reconocimiento de Formas y Aprendizaje Computacional

Trabajo Academico

Luis Alfonso Cardoza Bird

17 de Octubre de 2023

Cifar 100

Introduccion

Utilizando como base el **dataset** de **CIFAR-100**, se haran diversos procesos de clasificación de imágenes.

Objetivo

- Proveer un **dataset** standard, que compare clasificadores de imágenes.

Importando Datos / Etiquetas

```
(X_train, Y_train), (X_test, Y_test) = cifar100.load_data()
```

> Downloading data from https://www.cs.toronto.edu/~kriz/cifar-100-python.tar.gz 169001437/169001437

Se requiere tener una base de datos para poder efectuar nuestro análisis.

```
fine_labels =  [
    'apple',
```

```
    'aquarium_fish',
    'baby',
    ...
    ]
    for instances in fine_labels:
        class_names.update({counter: instances})
        counter+=1
```

Se realiza una iteración para poder obtener los etiquetados que van a ser utilizados para nuestras clasificaciones.

Escaneado de Imágenes

```
from random import randint

fig_display = plt.figure(figsize=[10,  10])
chosen_idx =  randint(0,  50000-21)

for indx in  range(chosen_idx, chosen_idx+20,  1):
    axes = fig_display.add_subplot(4,  5, indx - chosen_idx +1)
    axes.imshow(X_train[indx,  :,  :])
    axes.set_xticks([  ])
    axes.set_yticks([  ])
    axes.set_title("Class: {}".format(class_names[Y_train[indx,0]]))
```

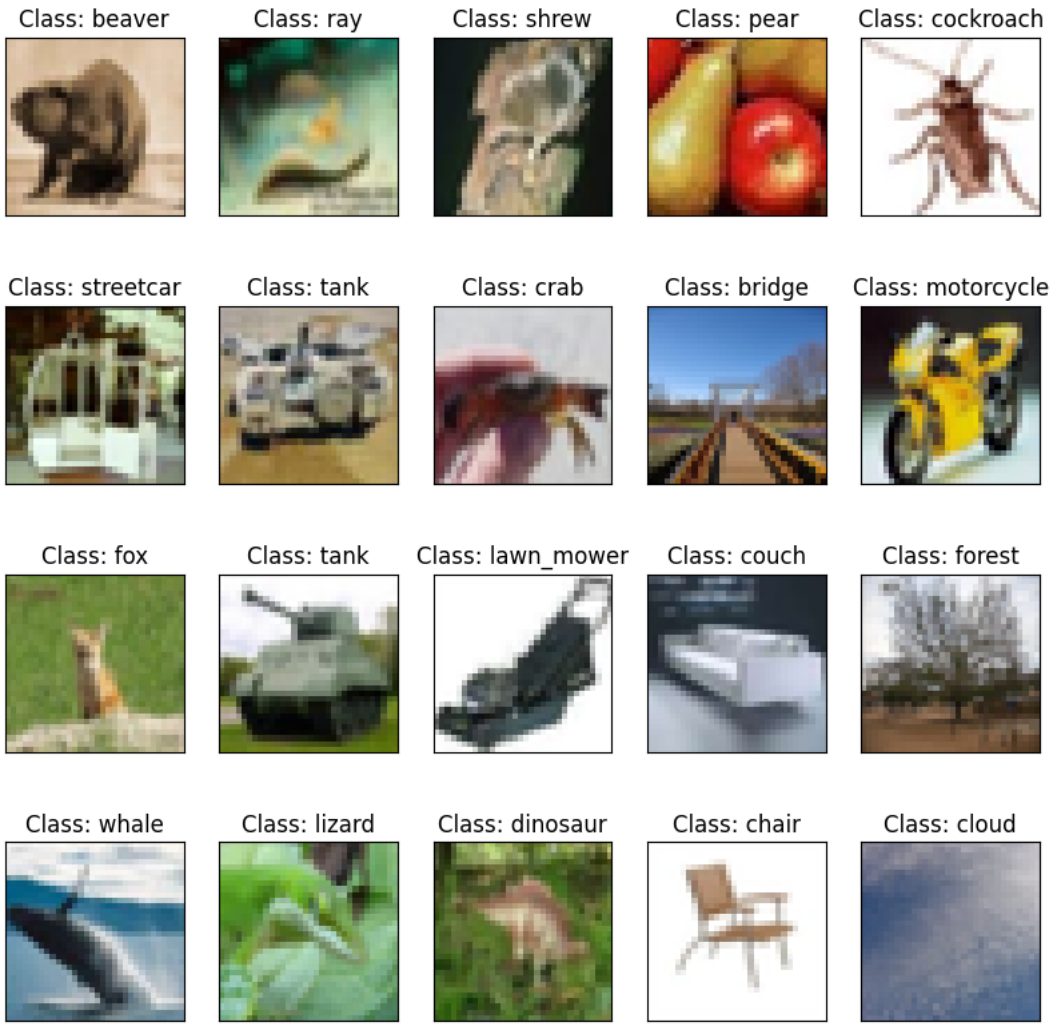

Categorizacion de Etiquetas

Hace referencia a la transformación de las etiquetas por categorías previamente mencionadas con el dataset de imanes para dar lugar a un formato que pueda procesar y comprender eficientemente dicha clasificación.

Es necesario utilizar el metodo ***One-hot encoding*** para obtener los mejores resultados.

One hot

```
onehot_train =  to_categorical(Y_train)
onehot_test =  to_categorical(Y_test)

print(onehot_train[:2])
```

```
[
    [0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 1.,
     0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.,
     0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.,
     0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.,
     0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
    [0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.,
     0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0.,
     0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.,
     0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.,
     0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
]
```

Estructura

Layer (type)	Output Shape	Param #
conv2d_8 (Conv2D)	(None, 32, 32, 32)	896
conv2d_9 (Conv2D)	(None, 32, 32, 32)	9,248
dropout (Dropout)	(None, 32, 32, 32)	0
max_pooling2d_8 (MaxPooling2D)	(None, 16, 16, 32)	0
conv2d_10 (Conv2D)	(None, 16, 16, 64)	18,496
conv2d_11 (Conv2D)	(None, 16, 16, 64)	36,928
leaky_re_lu_10 (LeakyReLU)	(None, 16, 16, 64)	0
max_pooling2d_9 (MaxPooling2D)	(None, 8, 8, 64)	0
conv2d_12 (Conv2D)	(None, 8, 8, 128)	73,856
conv2d_13 (Conv2D)	(None, 8, 8, 128)	147,584
...	...	...

Total params: 1,316,356
Trainable params: 1,316,356
Non-trainable params: 0

Esta tabla genera un resumen de cada capa con su respectivo tipo, forma final y el numero de parámetros involucrados.

Las celdas finales indica el total de parámetros que están en la red, y distingue entre los que son entrenables y no entrenables.

Extra

El modelo puede recibir multiples parámetros para hacerlo aun mas preciso, sin embargo se debe conocer que esto requiere mayor fuerza de equipo de computo.

Precision vs Perdida

Loss Function (Test Loss), indica que tan bien el modelo predice la data que no ah visto durante el entrenamiento.

Test Accuracy, representa el porcentaje de predicciones correctas hechas por el modelo para la data que no ah visto.

```
test_loss, test_acc = model_CNN.evaluate(X_test_scl, onehot_test,  verbose=False)
print("Test loss:", test_loss)
print("Test accuracy:", test_acc)
```

> **Test loss**: 5.0816216468811035 **Test accuracy**: 0.41100001335144043

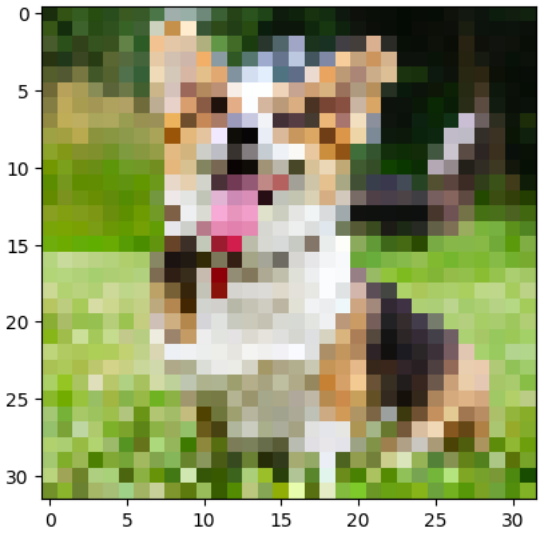

> Predicted class: spider <matplotlib.image.AxesImage at 0x7fde2207c0a0>

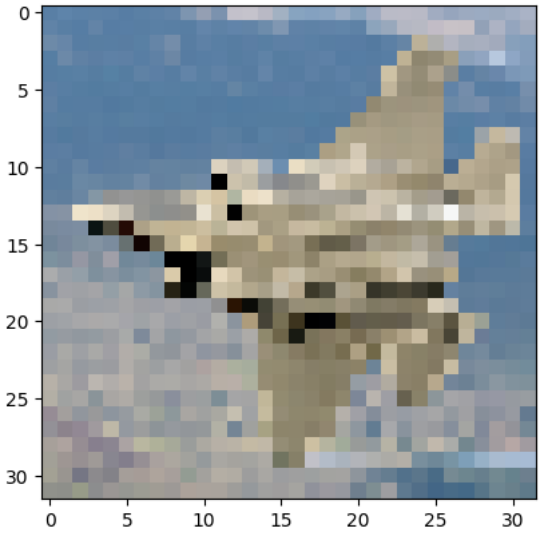

> 1/1 [==============================] - 0s 361ms/step Predicted class: dinosaur <matplotlib.image.AxesImage at 0x7fde221618b0>

Reevaluacion

```
from keras.losses import categorical_crossentropy

model_CNN.compile(loss=  'categorical_crossentropy',  optimizer=Adam(),  metrics=['accuracy'])
model_histo = model_CNN.fit(X_train_scl, onehot_train,  batch_size=batch_size,  epochs=epochs)
```

Las predicciones fueron erróneas por lo cual se procede a realizar un entrenamiento mas intensivo utilizando **Convolutional Neural Network**

Resultados de la reevalucion

> **Test loss**: 5.0816216468811035 **Test accuracy**: 0.41100001335144043

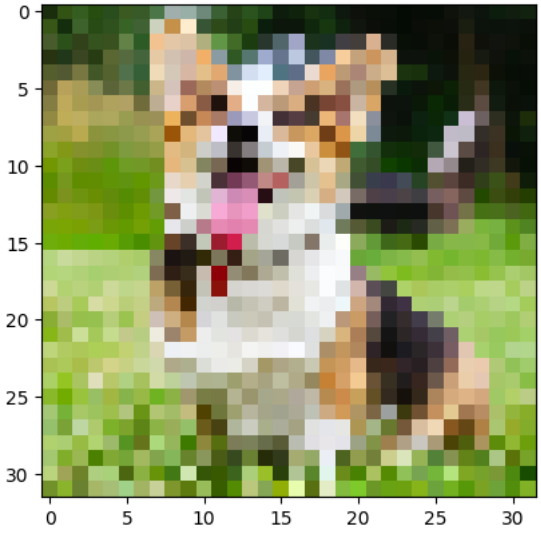

Predicted class: bee <matplotlib.image.AxesImage at 0x7fde2207c0a0>

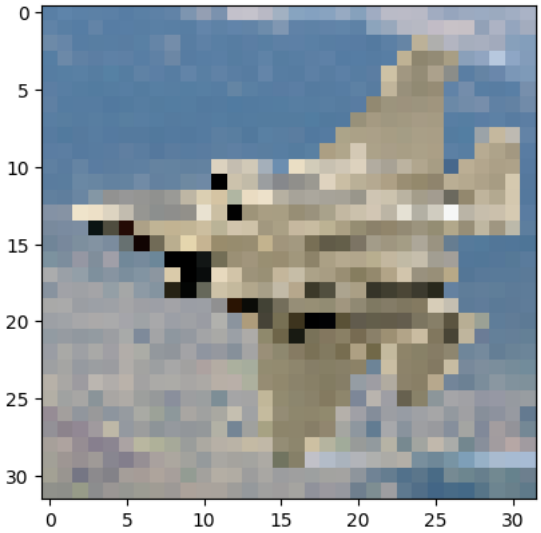

1/1 [==============================] - 0s 361ms/step Predicted class: plane <matplotlib.image.AxesImage at 0x7fde221618b0>

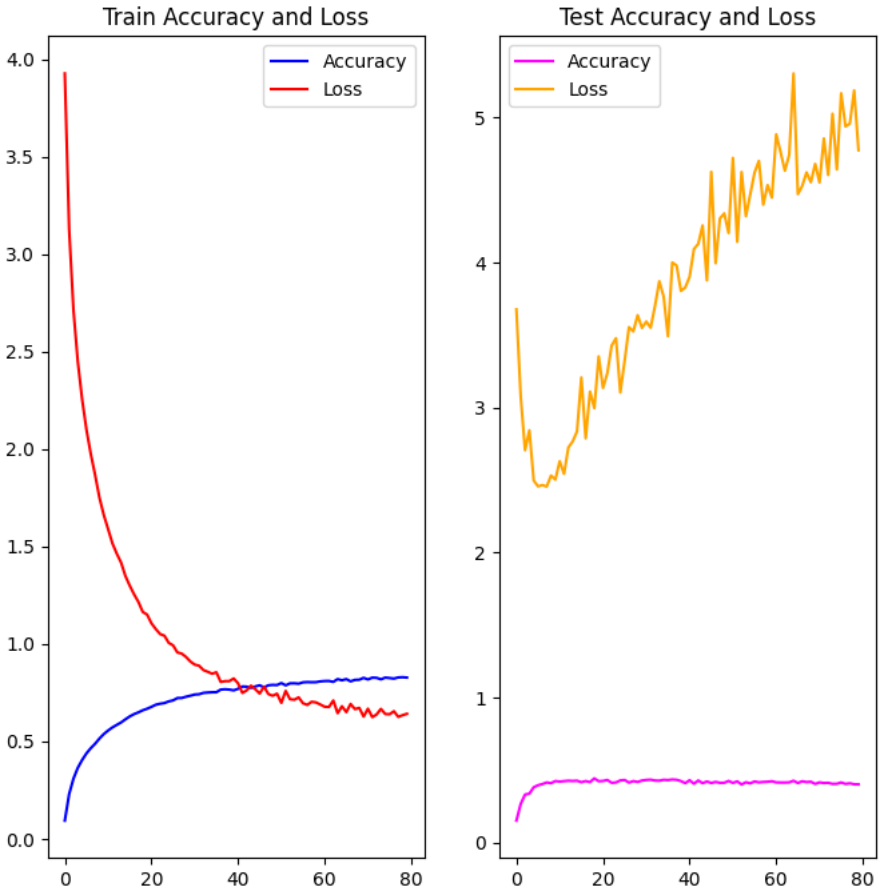

Network Architecture

```
from keras.layers import Conv2D, MaxPooling2D

# Function to create AlexNet-like model
def alexnet_model():
    model = Sequential()

    # First Convolutional Layer
    model.add(Conv2D(filters=96, kernel_size=(11,11), strides=(4,4), padding='valid',
                     activation='relu', input_shape=(32,32,3)))
    model.add(MaxPooling2D(pool_size=(2,2), strides=(2,2), padding='valid'))

    # Second Convolutional Layer
    model.add(Conv2D(filters=256, kernel_size=(11,11), strides=(1,1), padding='valid',
                     activation='relu'))
    model.add(MaxPooling2D(pool_size=(2,2), strides=(2,2), padding='valid'))

    # Additional Convolutional Layers
    model.add(Conv2D(filters=384, kernel_size=(3,3), strides=(1,1), padding='valid',
                     activation='relu'))
    model.add(Conv2D(filters=384, kernel_size=(3,3), strides=(1,1), padding='valid',
                     activation='relu'))
    model.add(Conv2D(filters=256, kernel_size=(3,3), strides=(1,1), padding='valid',
                     activation='relu'))
    model.add(MaxPooling2D(pool_size=(2,2), strides=(2,2), padding='valid'))

    # Passing it to a Fully Connected layer
    model.add(Flatten())
    # 1st Fully Connected Layer
    model.add(Dense(4096, activation='relu'))
    model.add(Dropout(0.5))

    # 2nd Fully Connected Layer
    model.add(Dense(4096, activation='relu'))
    model.add(Dropout(0.5))

    # Output Layer
    model.add(Dense(100, activation='softmax'))  # We have 100 classes in the CIFAR-100 dataset

    model.compile(optimizer=Adam(), loss='categorical_crossentropy', metrics=['accuracy'])
    return model
```

```
# Create AlexNet model
alexnet = alexnet_model()
alexnet.summary()
```

Este modelo es una variante de la red neuronal convolucional, se utiliza para clasificar imágenes, y es una de las redes neuronales convolucionales más influyentes en el campo de la visión por computadora.

FineTuning ResNet50

```
from keras.applications import ResNet50, InceptionV3, DenseNet121
from keras.models import Model
from keras.layers import GlobalAveragePooling2D

# Define input shape
input_shape = (32, 32, 3)  # CIFAR-100 images are 32 x 32

# Load pre-trained models
resnet_model = ResNet50(weights='imagenet', include_top=False, input_shape=input_shape)
inception_model = InceptionV3(weights='imagenet', include_top=False, input_shape=input_shape)
densenet_model = DenseNet121(weights='imagenet', include_top=False, input_shape=input_shape)

# Function to add new layers and compile the model for fine-tuning
def prepare_model_for_finetuning(base_model):
    x = base_model.output
    x = GlobalAveragePooling2D()(x)
    x = Dense(1024, activation='relu')(x)  # We add dense layers so that the model can learn more complex functions
    predictions = Dense(100, activation='softmax')(x)  # Final layer with softmax activation for 100 classes
    model = Model(inputs=base_model.input, outputs=predictions)

    # Compile the model
    model.compile(optimizer=SGD(lr=0.0001, momentum=0.9), loss='categorical_crossentropy', metrics=['accuracy'])
    return model

# Prepare models for fine-tuning
resnet_model_ft = prepare_model_for_finetuning(resnet_model)
inception_model_ft = prepare_model_for_finetuning(inception_model)
densenet_model_ft = prepare_model_for_finetuning(densenet_model)

# Model summaries
resnet_model_ft.summary()
inception_model_ft.summary()
densenet_model_ft.summary()
```

Podemos observar que el modelo de ResNet50 tiene 23,587,712 parámetros, el modelo de InceptionV3 tiene 21,802,784 parámetros y el modelo de DenseNet121 tiene 8,062,504 parámetros. Estos modelos son muy grandes para nuestro conjunto de datos CIFAR-100, por lo que vamos a realizar un ajuste fino de estos modelos para que puedan aprender a clasificar imágenes de CIFAR-100.

Conclusiones

Al preprocesar los datos de CIFAR-100 y lograr implementar una Red Neuronal Convolucional se puede lograr observar como mediante utilización de optimizados, funciones de perdida de entropía cruzada y entrenamiento efectivo. El proceso analítico y de evaluación se volvía cada vez mas consistente para lograr soluciones de aprendizaje automático de alto rendimiento.

Fashion MNIST

Introduccion

Utilizando como base el **dataset** de **Fashion MNIST**, se hará clasificacion de los procesos y resultados, enfocados en la clasificación de imágenes.

Objetivo

- Desarrollar una red neuronal capaz de identificar y categorizar diferentes prendas de vestir utilizando imágenes como base de aprendizaje.

Dimensiones

> Shape of train_images: (50000, 28, 28) Shape of train_labels: (50000,)

Análisis Estadístico de la Descripción de Imágenes

- Tabla utilizando `df_train_images.describe()`

```
.dataframe tbody tr th {
    vertical-align: top;
}

.dataframe thead th {
    text-align: right;
}
```

	0	1	2	3	4	5	6	7	8
count	50000.000000	50000.000000	50000.000000	50000.000000	50000.000000	50000.000000	50000.000000	50000.000000	50000.
mean	0.000900	0.006160	0.030940	0.107540	0.253580	0.410060	0.809520	2.248940	5.7208
std	0.100893	0.269673	0.800147	2.558106	4.300201	5.765828	8.236479	14.342265	23.923
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.0000
25%	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.0000
50%	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.0000
75%	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.0000
max	16.000000	36.000000	119.000000	164.000000	224.000000	230.000000	221.000000	221.000000	254.00

8 rows × 784 columns

La tabla generada utilizando `df_train_images.describe()` brinda un resumen estadístico para el dataset de los valores de pixels de imágenes, brindando valores provisionales como lo son `moda`, `desviación standard std`, `rango mínimo y Maximo`, y nos brinda la capacidad de conocer el nivel de `dispersion` y `tendencia de los datos centrales`.

Valores Perdidos

```
0
```

Los valores perdidos son datos que al momento de entrenar/analizar son omitidos o no pueden ser analizados, el objetivo principal es llegar lo mas cercano a `0`.

Etiquetadores

Indice	Valor
0	T-shirt/top
1	Trouser
2	Pullover
3	Dress
4	Coat
5	Sandal
6	Shirt
7	Sneaker
8	Bag
9	Ankle boot

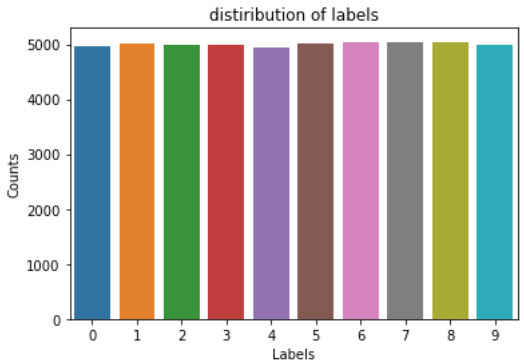

Esta distribución indica que prendas se asocian con los etiquetadores otorgados.

Creacion de modelos y métricas

```
def  yeniModelOlustur(input_shape=img_shape):
    model =  Sequential([
        base_layer(16,input_shape),
        Conv2D(16,3,padding='same',activation='relu'),
        conv_layer(32),
        Dropout(0.1),
        conv_layer(64),
        Dropout(0.2),
        conv_layer(128),
        Dropout(0.25),
        conv_layer(256),
        Conv2D(256,3,padding='same',activation='relu'),
        Dropout(0.3),
        MaxPool2D(pool_size=(2,2),padding='same'),
        Flatten(),
        dense_layer(128,0.6),
        dense_layer(64,0.4),
        output_layer(10)
    ])
    return model
```

```
m =  yeniModelOlustur()
m.compile(loss='categorical_crossentropy',optimizer='adam',metrics=['accuracy'])
m.summary()
```

Resultado

Layer (type)	Output Shape	Param #
InitLayer (Sequential)	(None, 28, 28, 16)	160
conv2d_1 (Conv2D)	(None, 28, 28, 16)	2320
sequential (Sequential)	(None, 14, 14, 32)	14016
dropout (Dropout)	(None, 14, 14, 32)	0
sequential_1 (Sequential)	(None, 7, 7, 64)	55680
dropout_1 (Dropout)	(None, 7, 7, 64)	0
sequential_2 (Sequential)	(None, 3, 3, 128)	221952
dropout_2 (Dropout)	(None, 3, 3, 128)	0
sequential_3 (Sequential)	(None, 1, 1, 256)	886272
conv2d_10 (Conv2D)	(None, 1, 1, 256)	590080
dropout_3 (Dropout)	(None, 1, 1, 256)	0
...	...	...
Total params: 1,813,050		
Trainable params: 1,811,706		
Non-trainable params: 1,344		

Esta tabla genera un resumen de cada capa con su respectivo tipo, forma final y el numero de parámetros involucrados.

Las celdas finales indica el total de parámetros que están en la red, y distingue entre los que son entrenables y no entrenables.

Evaluación de Pérdidas y Precisión

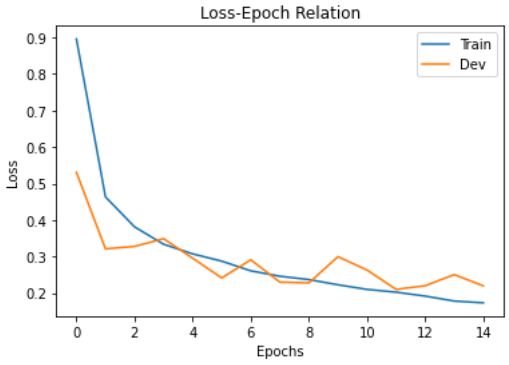

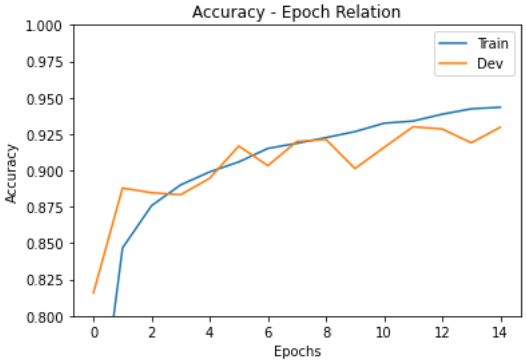

- En la primera grafica se visualiza la perdida del modelo en el entrenamiento y validación, mientras prosigue con los temas sets de entrenamiento.
- En la segunda gráfica se visualiza la precision del modelo para ambos sets de datos, dando indicios del la eficacia de aprendizaje con el modelo.

Fine Tuning

1. Early Stopping

```
checkpoint_fm =  ModelCheckpoint("fashion_mnist_model.h5",  save_best_only=True)
early_stopping_fm =  EarlyStopping(patience=10,  restore_best_weights=True)
```

2. Learning Rate Decay

```
def  exponential_decay(learning_rate,  decay_step):
    def  exponential_decay_fm(epoch):
        return learning_rate *  0.1  **(epoch / decay_step)
return exponential_decay_fm

exponential_decay_fm =  exponential_decay(0.01,  10)
lr_scheduler =  LearningRateScheduler(exponential_decay_fm)
```

Re-evaluacion después de aplicar FINE-TUNING

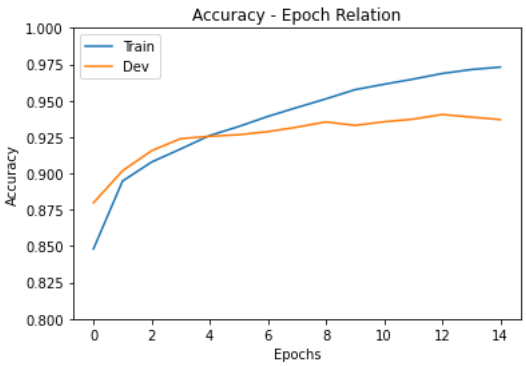

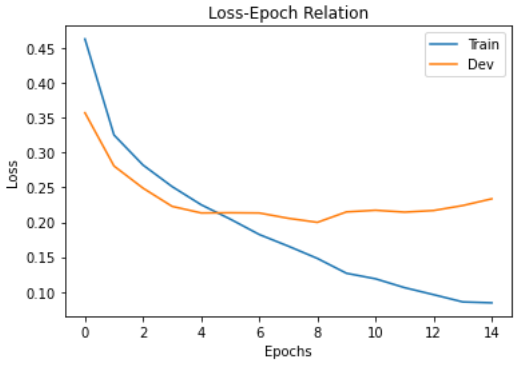

Resultados Finales

Dataset	Accuracy
Train	0.9730799794197083
Dev	0.9369937181472778
Test	0.9352999925613403

FineTuning ResNet50

```
from keras.applications import ResNet50, MobileNet
from keras.layers import Input, Lambda
from keras.models import Model
from keras.layers import GlobalAveragePooling2D
from keras import backend as K

# Define input shape
input_shape = (28, 28, 1)  # Fashion MNIST images are 28x28 and grayscale

# Function to convert grayscale images to RGB
def gray_to_rgb(x):
    return K.stack([x] * 3, axis=-1)

# Prepare the input layer and convert images from grayscale to RGB
input_tensor = Input(shape=input_shape)
rgb_tensor = Lambda(gray_to_rgb)(input_tensor)

# Load pre-trained models
resnet_model = ResNet50(weights='imagenet', include_top=False, input_tensor=rgb_tensor)
mobilenet_model = MobileNet(weights='imagenet', include_top=False, input_tensor=rgb_tensor)

# Function to add new layers and compile the model for fine-tuning
def prepare_model_for_finetuning(base_model):
    x = base_model.output
    x = GlobalAveragePooling2D()(x)
    x = Dense(1024, activation='relu')(x)  # We add dense layers so that the model can learn more complex functions
    predictions = Dense(10, activation='softmax')(x)  # Final layer with softmax activation for 10 classes
    model = Model(inputs=base_model.input, outputs=predictions)

    # Compile the model
    model.compile(optimizer=SGD(lr=0.0001, momentum=0.9), loss='categorical_crossentropy', metrics=['accuracy'])
    return model

# Prepare models for fine-tuning
resnet_model_ft = prepare_model_for_finetuning(resnet_model)
mobilenet_model_ft = prepare_model_for_finetuning(mobilenet_model)

# Model summaries
resnet_model_ft.summary()
mobilenet_model_ft.summary()
```

Podemos observar que el modelo de ResNet50 tiene 23,587,712 parámetros, el modelo de InceptionV3 tiene 21,802,784 parámetros y el modelo de DenseNet121 tiene 8,062,504 parámetros. Estos modelos son muy grandes para nuestro conjunto de datos CIFAR-100, por lo que vamos a realizar un ajuste fino de estos modelos para que puedan aprender a clasificar imágenes de CIFAR-100.

Conclusiones

Se puede concluir que el modelo ah sido desarrollado, entrenado y optimizado metódicamente para clasificar imágenes usando el **dataset Fashin MNIST**.

Los resultados iniciales indicaron un rendimiento prometedor, el cual fue validado intensivamente.

Las métricas de visualización de perdida y precision sobre los segmentos de entrenamiento proveen demostraciones de la aplicación de los principios de **DeepLearning** y de los protocolos de evaluación.